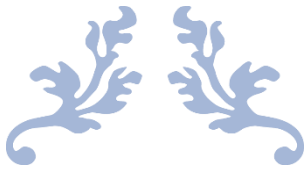

微博热搜分析

学号：10215501450

姓名：刘钊瑄

目录

1 实验引言

1.1 研究背景

2022 年 12 月中旬，各类新闻层出不穷，本身就处于信息传播迅速的时代，恰逢这届不断爆冷的世界杯进入决赛阶段，阿根廷万众瞩目，又赶上国内开放的浪潮，消息更是眼花缭乱。于是突发奇想，想把信息整合可视化处理一下，以此更好地探究、观察并记录时下热点。毕竟信息爆炸的时代，消息太多了，就以微博为例，一天能有三四百条不一样的热搜，很多上榜时间短，尚未来得及看到就掉了或者被压了，所以想借此机会，记录没有记忆的互联网，并对每天的新闻有一个大致的把握。

新浪微博目前是国内第一的社交媒体，热搜榜每分钟实时更新，而微博提出的“最新鲜、最热门、最有料”也使其成为用户心中毫无疑问的 top 热搜榜。因此，该项目选择了新浪微博这一平台作为数据来源，专门对其热搜榜上的数据进行爬取与分析。

2 问题描述

2.1 研究题目

总的来说，该项目首先是爬取微博热搜榜数据，再着重对微博热搜进行可视化处理，做成柱状图、动态柱状图和折线图等图表，还有词云，并做相关情感分析，来看网上舆论的情感倾向，同时结合词云做一个对比。最后结合相关信息做一个热搜走势的拟合，来探究走势并预测其他未知热搜的潜力。

2.2 研究难点

① 数据获取：自学爬虫。开始有点艰难，完全看不懂 html，后面逐渐上手，还是实践出真知，且手机模式加密少，更容易。

② 可视化：词云制作里有很多停用词，还有一些词语划分要手动调整，动态柱状图的布局也需调整。

③ 拟合：一开始想最小二乘来拟合，最后试了很多，还是用了 numpy 库里的 polyfit 来处理，处理得比较粗糙，重点放在了可视化展示。

3 实验方法

① 在 Windows 环境下，利用 vscode (python 3.10.2) 和 jupyter notebook(python 3.9.12)来挖掘和可视化数据，用 Excel 来存储 csv 数据。数据挖掘时，用任务计划程序来定时重复执行爬虫代码，获取原始数据。

② 调用 pyecharts，plotly 和 matplotlib 等库来进行数据可视化，jieba 库来分词处理文本，snownlp 进行情感分析，wordcloud 制作词云。

4 实验过程

4.1 数据获取

首先导入需要用到的库，

```
import requests  # 向页面发送请求
import csv       # 写入 csv 文件
from bs4 import BeautifulSoup as BS   # 解析页面
import time      # 记录爬虫的时间
```

再定义一个爬取的目标地址，

```
url = 'https://s.weibo.com/top/summary?cate=realtimehot'
```

然后定义一个请求头，

```
headers = {
    'User-Agent': 'Mozilla/5.0 (Linux; Android 8.0.0; SM-G955U Build/R16NW) AppleWebKit/537.36 (KHTML, like Ge
    'Host': 's.weibo.com',
    'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,image/webp,image/apng,*/*;q=0.8,applicati
    'Accept-Language': 'zh-CN,zh;q=0.9,en;q=0.8,en-GB;q=0.7,en-US;q=0.6',
    'Accept-Encoding': 'gzip, deflate, br',
    'Cookie': 'SINAGLOBAL=2299625611123.144.1670911291558; SCF=Avg3iCW-ED4m2pzB66A7ImFVKQWSnoFyWTyyTpIV5-myioE
```

这些参数在开发者模式里可以找到，这里是用手机模式爬取的，减少加密困难。

接下来向页面发送请求并解析返回的页面。

```
1.    response = requests.get(url = url, headers = headers)
2.    # print(response.status_code) 如果返回 200 则正常，404 是未找到
3.    response.encoding = "utf_8_sig"
4.    soup = BS(response.text, "html.parser")
```

根据页面分析，每条热搜都放在了标签为 section class = “list”的数据里，里面每条热搜，又是 li 下的一个 a 标签。

于是根据这个思路，再去除置顶，处理标签为空的情况。将标题、排名、热度、标签、时间组成一个小列表 list_t，放入大列表 List 中，便于写入 csv。代码如下：

```
    div_content = soup.find('section', {'class': 'list'})
    t = 1 # 去掉置顶
    list_t = []
    List = []
    for item in div_content.find_all("li"):
        if(t == 1):
            t = 0
            continue
        rank = item.find("strong").string  # 排名
        subject = item.span.contents[0]   # 标题
        hotness = item.find("em").string  # 热度
        if(item.find("i")):
            sign = item.find("i").get("class")[1]   # 标签
        else:
            sign = 'None'
        current_time = time.strftime("%Y-%m-%d %H:%M")
        list_t = [subject, rank, hotness, sign, current_time]
        List.append(list_t)
```

最后将 List 写入 csv 文件：

```
    def store(List):
        with open('D:/code/12_23.csv', 'a', encoding = "utf_8_sig", n
    ewline = "") as file:
            writer = csv.writer(file)
            for item in List:
                writer.writerow(item)
            file.close()
```

A1 华西医院23岁医学生抢救无效去世

	A	B	C	D	E
1	华西医院23岁医学生抢救无效去世	1	2921285	icon_new	2022/12/15 8:00
2	法国2比0摩洛哥	2	1175558	None	2022/12/15 8:00
3	儿童感染奥密克戎应注意这几点	3	933085	None	2022/12/15 8:00
4	OPPO Find N2 系列发布			icon_recommend	2022/12/15 8:00
5	杭州核酸单管每人次16元	4	824289	None	2022/12/15 8:00
6	阳了真的会浑身疼吗	5	799083	icon_new	2022/12/15 8:00
7	同事阳了自己不去上班算旷工吗	6	748230	None	2022/12/15 8:00
8	我的守护星			icon_recommend	2022/12/15 8:00
9	姆巴佩进球比赛法国从未输球	7	697509	None	2022/12/15 8:00

由于需要长时间反复爬取，无法人工完成，于是设定任务计划程序来完成：

每天早上 8 点到晚上 10 点，每隔 10 分钟执行一次程序。

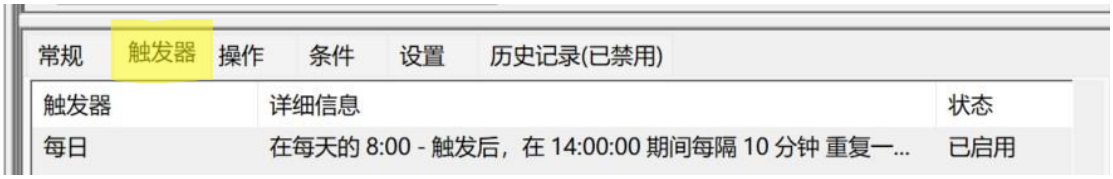

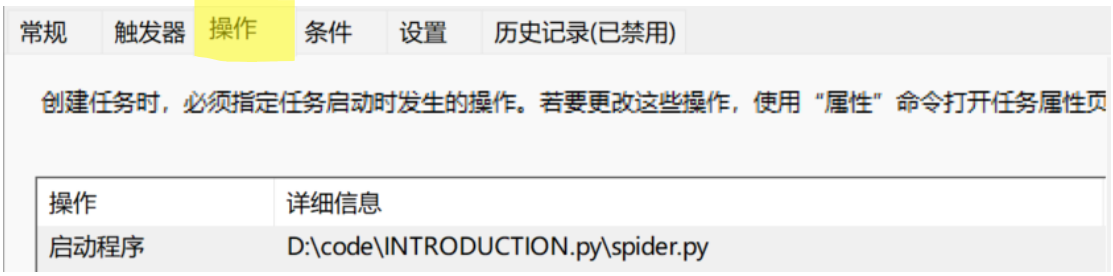

每天的热搜都保存为一个 csv 文件，该项目爬取了一个礼拜 7 天的热搜，分别保存，共 7 个 csv 文件。每次爬取包括广告和目标的五十条热搜信息，一天执行 85 次程序，预处理后共 4250 条一天。

4.2 数据预处理

4.2.1 剔除广告

413	华西医院23岁医学生抢救无效去世	1	4380431	icon_boil	2022/12/15 9:20
414	女子坐地铁不戴口罩称有病毒的人才戴	2	1947666	icon_new	2022/12/15 9:20
415	儿童感染奥密克戎应注意这几点	3	1643571	icon_boil	2022/12/15 9:20
416	苏醒实现电视自由			icon_recommend	2022/12/15 9:20
417	阳了真的会浑身疼吗	4	1369589	None	2022/12/15 9:20
418	至今还未感染的你是怎么做到的	5	1221506	icon_new	2022/12/15 9:20
419	法国2比0摩洛哥	6	976020	None	2022/12/15 9:20
420	宝贝成长守护计划			None	2022/12/15 9:20
421	杨迪晒阳敌表情包	7	865106	icon_new	2022/12/15 9:20
422	中国医药与辉瑞公司签订协议	8	788825	None	2022/12/15 9:20
423	少爷和我	9	674556	None	2022/12/15 9:20
424	张杰也逃不过家长群接龙	10	588791	icon_hot	2022/12/15 9:20

微博热搜榜自带广告推荐，有的标签是 icon_recommend，有的无标签，但都不存在热度且不参与排名，所以直接剔除有空值的条目。以 12 月 15 号的数据为例：

```
7   data = pd.read_csv('days/12_15.csv', header = None, encoding = 'utf-8-sig')
8   print("处理前: %d条" % data.shape[0])
9   data = data.dropna()
10  print("剔除热度为0后: %d条" % data.shape[0])
```

```
PROBLEMS  OUTPUT  TERMINAL  DEBUG CONSOLE

PS D:\code> python -u "d:\code\INTRODUCTION.py\nlp_day.py"
处理前: 4386条
剔除热度为0后: 4250条
PS D:\code>
```

4.2.2 部分处理时剔除每天最后五十条

在制作每小时的情感分析图时，每小时截取的是 0 分到 50 分 6 个时间点，而数据集是 8 点整到 22 点整，所以处理时选择删去最晚的 22 点整，最后合并为 1 个 csv，来制作一天 14 个小时的七天情感分析图。

此处要先剔除广告后，重新编号，才能将最后五十条热搜去除，也可以根据时间删除：

```
1.    def clean(f_1):
2.        f_1 = f_1.dropna()
3.        f_1 = f_1.reset_index()
4.        f_1.drop(f_1.tail(50).index, inplace = True)
5.        return f_1
```

处理前 7 个单独的 csv，共 30555 条，处理完后共有 29400 条：

```
12  f_1 = pd.read_csv('days/12_15.csv', header = None, encoding = 'utf-8-sig')
13  f_2 = pd.read_csv('days/12_16.csv', header = None, encoding = 'utf-8-sig')
14  f_3 = pd.read_csv('days/12_17.csv', header = None, encoding = 'utf-8-sig')
15  f_4 = pd.read_csv('days/12_18.csv', header = None, encoding = 'utf-8-sig')
16  f_5 = pd.read_csv('days/12_19.csv', header = None, encoding = 'utf-8-sig')
17  f_6 = pd.read_csv('days/12_20.csv', header = None, encoding = 'utf-8-sig')
18  f_7 = pd.read_csv('days/12_21.csv', header = None, encoding = 'utf-8-sig')
19
20  l = [f_1, f_2, f_3, f_4, f_5, f_6, f_7]
21  data = pd.concat(l)
22  print("处理前: %d条" % data.shape[0])
23
24  f_1 = clean(f_1)
25  f_2 = clean(f_2)
26  f_3 = clean(f_3)
27  f_4 = clean(f_4)
28  f_5 = clean(f_5)
29  f_6 = clean(f_6)
30  f_7 = clean(f_7)
31  l = [f_1, f_2, f_3, f_4, f_5, f_6, f_7]
32  data = pd.concat(l)
33  print("处理后: %d条" % data.shape[0])
```

```
PROBLEMS  OUTPUT  TERMINAL  DEBUG CONSOLE

          > python -u "d:\code\INTRODUCTION.py\nlp_hour.py"
处理前: 30555条
处理后: 29400条
PS D:\code>
```

4.3 数据可视化

4.3.1 词云 wordcloud

这一部分主要是 jieba 库分词和 wordcloud 库的词云制作。

部分词语需要人工手动调整：

```
1.    jieba.suggest_freq('奥密克戎', True)
2.    jieba.suggest_freq('连花清瘟', True)
3.    jieba.suggest_freq('吞刀片', True)
4.    jieba.suggest_freq('咽口水', True)
5.    jieba.suggest_freq('C 罗', True)
6.    jieba.suggest_freq('发不雅信息', True)
7.    jieba.suggest_freq('川渝', True)
8.    jieba.suggest_freq('想见你', True)
9.    jieba.suggest_freq('黄子韬', True)
10.   jieba.suggest_freq('新冠', True)
11.   jieba.suggest_freq('撸下口罩', True)
12.   jieba.suggest_freq('姆巴佩', True)
13.   jieba.suggest_freq('涮肉', True)
14.   jieba.suggest_freq(('瘟', '能'), True)
15.   jieba.suggest_freq(('瘟', '一次'), True)
16.   jieba.suggest_freq(('期', '杀'), True)
```

也有很多停用词，这里数据量还行，所以没有查停用词表，手动输的，最后效果也不错：

```
stopwords = {'岁','的', '是', '吗', '和', '了', '被', '你', '这', '能', '至今', '颗',
             '怎么', '对', '已', '称有', 'vs', '成', '都', '有', '多', '还', '一起',
             '不戴', '我', '比', '贴', '层涨', '元', '摔', '条', '上', '千元', '还有',
             '卖', '到', '应', '后', '戴', '买', '吃', '天', '与', '却', '真的', '又',
             '不', '将', '宣布', '当定', '一盒', '会', '粒', '买块', '患', '嫌', '要',
             '点', '让', '一板', '只', '第', '再', '种', '什么', '一支', '不了', '千',
             '天内', '知道', '不到', '个', '为何', '才', '遇人', '或超', '薇给', '超',
             '给', '病', '因', '万买', '冠', '半', '一次', '它在', '想', '称', '穿', '疯',
             '度', '就', '在', '从', '摊', '它', '差点', '囤', '号', '叫', '全是', '带到',
             '为什么', '像', '是因为', '有人', '开', '时', '月', '轮', '斤', '小时', '造',
             '毛', '么', '她', '前', '年', '不是', '瘟', '称此', '做好', '哪', '我们',
             '例', '花', '把', '期间', '当回事', '如何', '增', '他们', '带来', '人', '期',
             '杀', '帮', '引', '或', '一', '名', '秒', '可', '写', '也', '没', ' 几乎',
             '地', '变', '忍住'})
```

制作了 7 天的词云图：

12 - 15

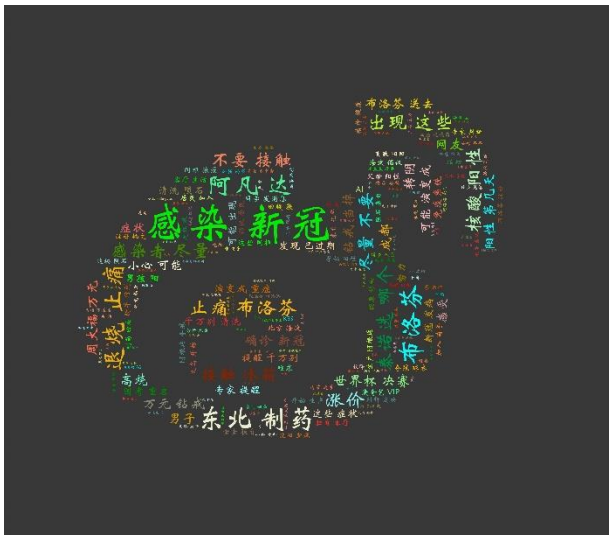

12 - 16

12 - 17

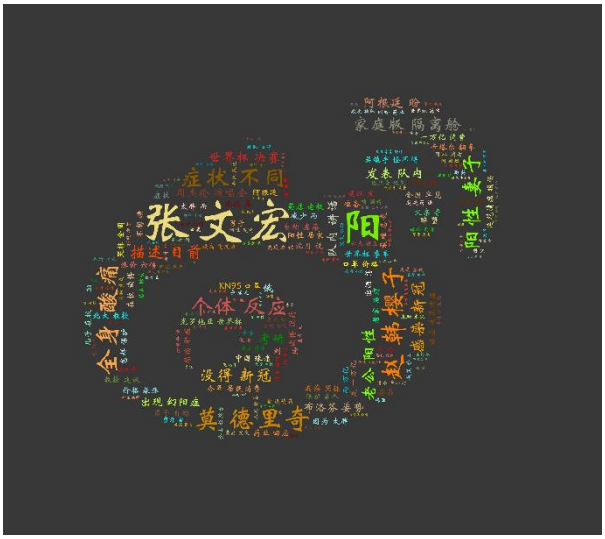

12 - 18

12 - 19

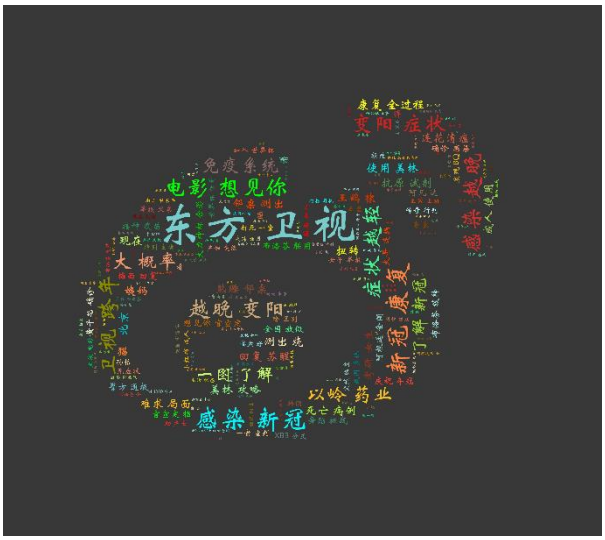

12 - 20

12 - 21

这些词云都用了微博标志大眼仔的蒙版，更好看一点。出现频率越高的词语在词云中显示的字号越大，此外还需加载中文本地的字体，这里用了黑体，所欲整个 word_cloud 定义是：

```
word_cloud = WordCloud(
        scale = 8,
        font_path = 'C:/Windows/Fonts/STXINWEI.TTF', # 显示中文需要加载本地中文字体
        background_color = '#383838',
        colormap = colormap,
        prefer_horizontal = 0.8, # 水平显示的文字相对于竖直显示文字的比例
        mask = icon, # 添加蒙版
        relative_scaling = 0.3, # 设置字体大小与词频的关联程度为0.3
        max_font_size = 80, # 设置显示的最大字体
        stopwords = {'岁','的', '是', '吗', '和', '了', '被', '你', '这', '能', '至今', '颗',
                     '怎么', '对', '已', '称有', 'VS', '成', '都', '有', '多', '还', '一起',
                     '不戴', '我', '比', '贴', '层涨', '元', '摔', '条', '上', '千元', '还有',
                     '卖', '到', '应', '后', '戴', '买', '吃', '天', '与', '却', '真的', '又',
                     '不', '将', '宣布', '当定', '一盒', '会', '粒', '买块', '患', '嫌', '要',
                     '点', '让', '一板', '只', '第', '再', '种', '什么', '一支', '不了', '干',
                     '天内', '知道', '不到', '个', '为何', '才', '遇人', '或超', '薇给', '超',
                     '给', '病', '因', '万买', '冠', '半', '一次', '它在', '想', '称', '穿', '疯',
                     '度', '就', '在', '从', '摊', '它', '差点', '囤', '号', '叫', '全是', '带到',
                     '为什么', '像', '是因为', '有人', '开', '时', '月', '轮', '斤', '小时', '造',
                     '毛', '么', '她', '前', '年', '不是', '瘟', '称此', '做好', '哪', '我们',
                     '例', '花', '把', '期间', '当回事', '如何', '增', '他们', '带来', '人', '期',
                     '杀', '帮', '引', '或', '一', '名', '秒', '可', '写', '也', '没', ' 几乎',
                     '地', '变', '忍住', '取决于'})
word_cloud.generate(words)
```

最后保存为. jpg 文件：

```
word_cloud.to_file('wc1.jpg')
```

后续会在情感分析部分一起分析 16 号和 19 号的词云。

4. 3. 2 每日关键词 top20

词云更适合展示，有时可能有些眼花缭乱，于是又做了每日关键词 top20，

更加简洁。前面一小部分处理与词云相同，从词义分割开始不一样，top20 用了字典来做词频统计并排序：

```
    words = jieba.lcut(str)
    word_dict = {}
    for word in words:
            if len(word) == 1: # 如果关键字字数为1，不统计；否则加1
                continue
            else:
                word_dict[word] = word_dict.get(word, 0) + 1
    word_zip = zip(word_dict.values(), word_dict.keys())
    word_sort = list(sorted(word_zip, reverse = True))# 对元组里面的元素按照 value 从大到小进行排序
```

用 matplotlib.pyplot 画图，图表字体设置为中文黑体：

```
    plt.rcParams['font.sans-serif'] = ['SimHei'] # 中文设置为黑体
```

标签太长显示不太友好，旋转 30 度：

```
    plt.xticks(rotation = 30) # x 轴标签旋转 30 度
```

最终效果：

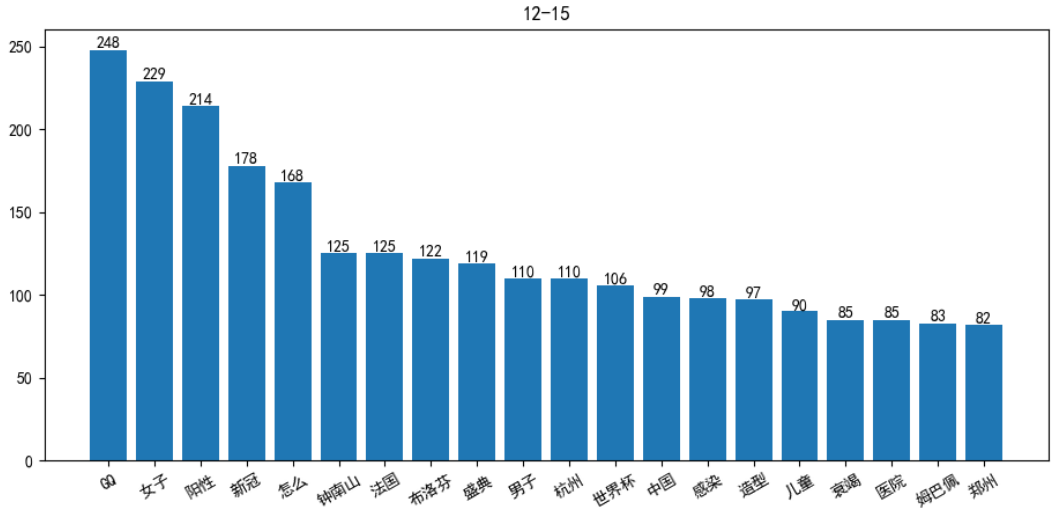

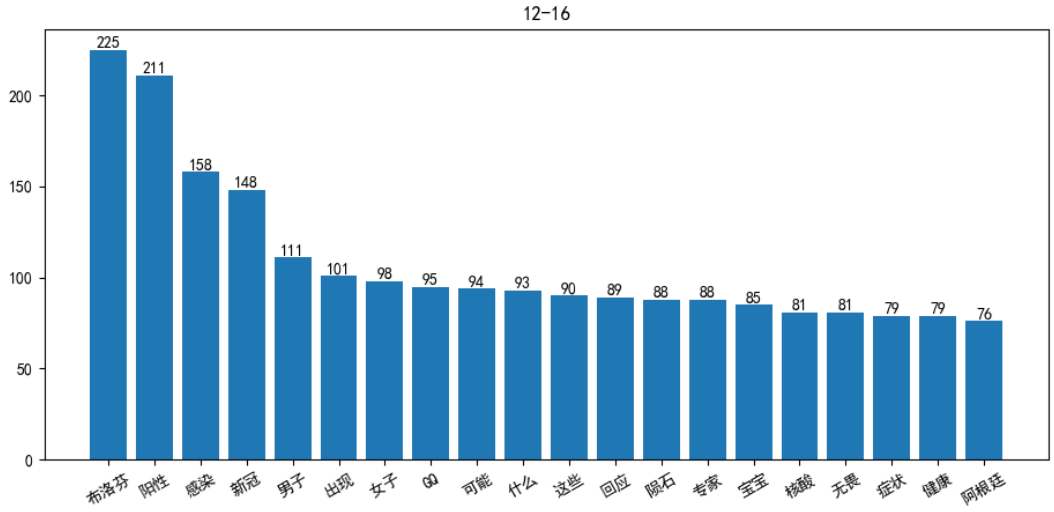

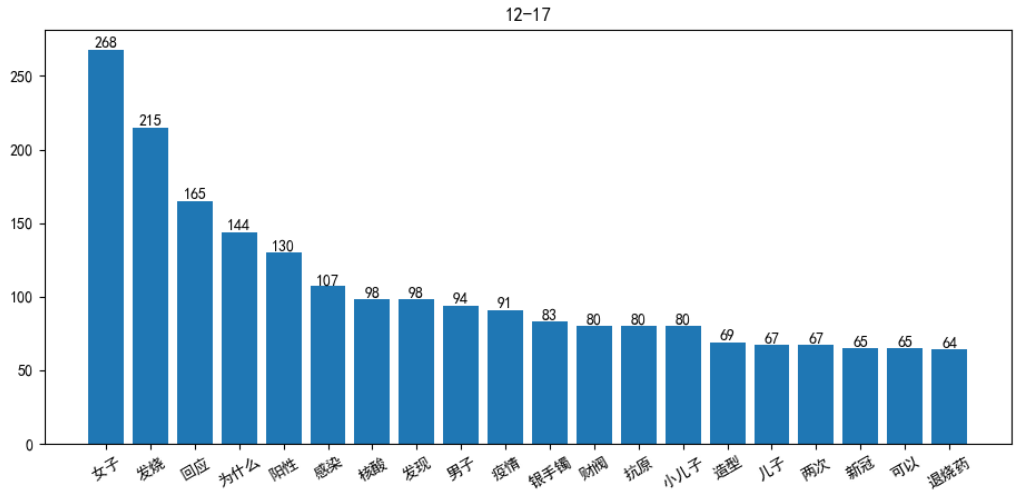
12-17
268
215
165
144
130
107
98
98
94
91
83
80
80
80
69
67
67
65
65
64
女子
发烧
回应
为什么
阳性
感染
核酸
发现
男子
疫情
银手镯
财阀
抗原
小儿子
造型
儿子
两次
新冠
可以
退烧药

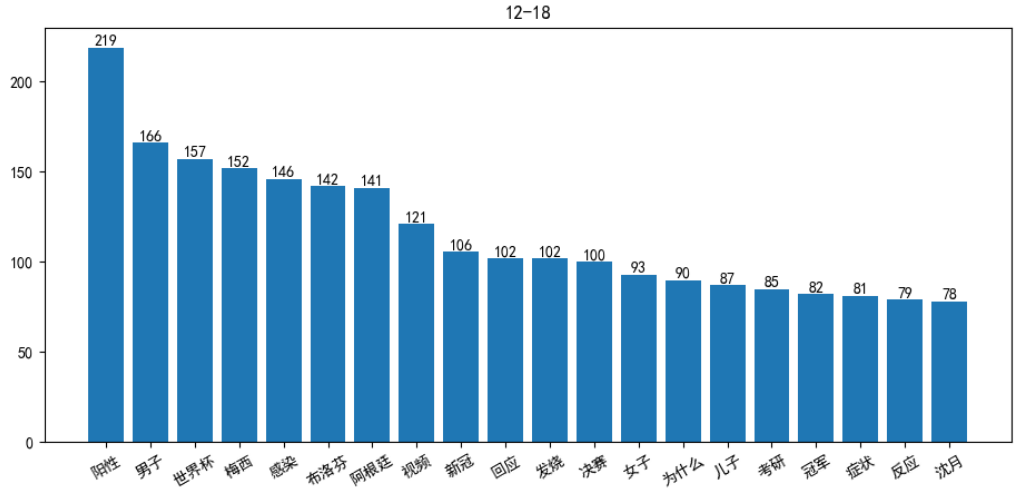
12-18
219
166
157
152
146
142
141
121
106
102
102
100
93
90
87
85
82
81
79
78
阳性
男子
世界杯
梅西
感染
布洛芬
阿根廷
视频
新冠
回应
发烧
决赛
女子
为什么
儿子
考研
冠军
症状
反应
沈月

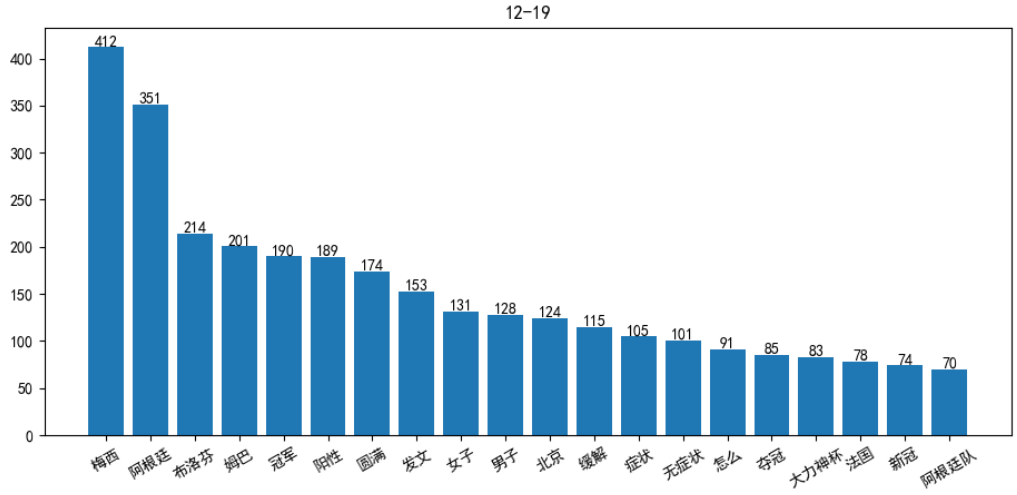
12-19
412
351
214
201
190
189
174
153
131
128
124
115
105
101
91
85
83
78
74
70
梅西
阿根廷
布洛芬
姆巴
冠军
阳性
圆满
发文
女子
男子
北京
缓解
症状
无症状
怎么
夺冠
大力神杯
法国
新冠
阿根廷队

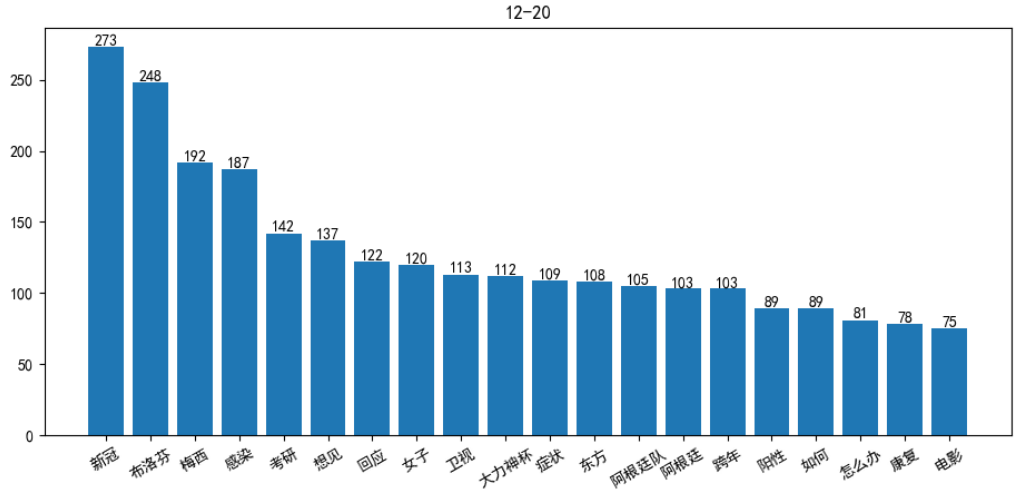
12-20
273
248
192
187
142
137
122
120
113
112
109
108
105
103
103
89
89
81
78
75
新冠
布洛芬
梅西
感染
考研
想见
回应
女子
卫视
大力神杯
症状
东方
阿根廷队
阿根廷
跨年
阳性
如何
怎么办
康复
电影

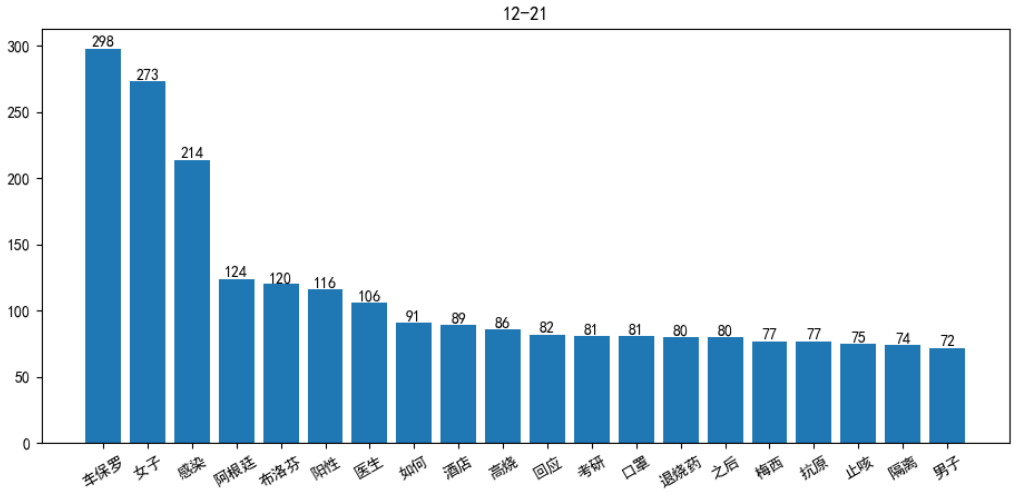

4.3.3 动态柱状图

这个是用 pyecharts 制作的，也是花费了很多力气，

最后用 jupyter notebook 加了这两行才能网页展示：

```
1.    from pyecharts.globals import CurrentConfig, NotebookType
2.    CurrentConfig.NOTEBOOK_TYPE = NotebookType.JUPYTER_NOTEBOOK
```

预处理只需要合并 7 个 csv 文件，去除空值行，其他不需要调整，共 29750 条。

```
f_1 = pd.read_csv('D:/code/days/12_15.csv', header = None, encoding = 'utf-8-sig')
f_2 = pd.read_csv('D:/code/days/12_16.csv', header = None, encoding = 'utf-8-sig')
f_3 = pd.read_csv('D:/code/days/12_17.csv', header = None, encoding = 'utf-8-sig')
f_4 = pd.read_csv('D:/code/days/12_18.csv', header = None, encoding = 'utf-8-sig')
f_5 = pd.read_csv('D:/code/days/12_19.csv', header = None, encoding = 'utf-8-sig')
f_6 = pd.read_csv('D:/code/days/12_20.csv', header = None, encoding = 'utf-8-sig')
f_7 = pd.read_csv('D:/code/days/12_21.csv', header = None, encoding = 'utf-8-sig')
l = [f_1, f_2, f_3, f_4, f_5, f_6, f_7]
data = pd.concat(l)
data = data.dropna()
print(data.shape[0])
'''tl = Timeline({"theme": ThemeType.MACARONS})
for i in range(588):
    bar = (Bar()
           .add_xaxis(list(data.iloc[:, 0])[i*50 : i*50 + 20][::-1])
           .add_yaxis("微博热搜榜", list(data.iloc[:, 2])[i*50 : i*50 + 20][::-1]).reversal_axis()
           .set_series_opts(label_opts = opts.LabelOpts(position = "inside"))
           .set_global_opts(title_opts=opts.TitleOpts(list(data.iloc[:, 4])[i*50 : i*50 + 1])))
    tl.add(bar, '')
    grid = (Grid().add(bar, grid_opts=opts.GridOpts(pos_left = "20%",pos_right = "0%")))  #将图形整体右移
    tl.add(grid, '')
    tl.add_schema(play_interval = 150, is_timeline_show = True, is_auto_play = False, is_loop_play = False)

tl.render('hot.html')'''
```

[1] ✓ 2.2s Python

```
29750
```

①② 由于大小限制以及美观，动态柱状图每次展示前 20 条热搜标题和热度；

③　标题显示时间，随着展示的时间轴变化。

最后动态展示速度设置为间隔 150ms，便于看清内容。

静态的效果图：

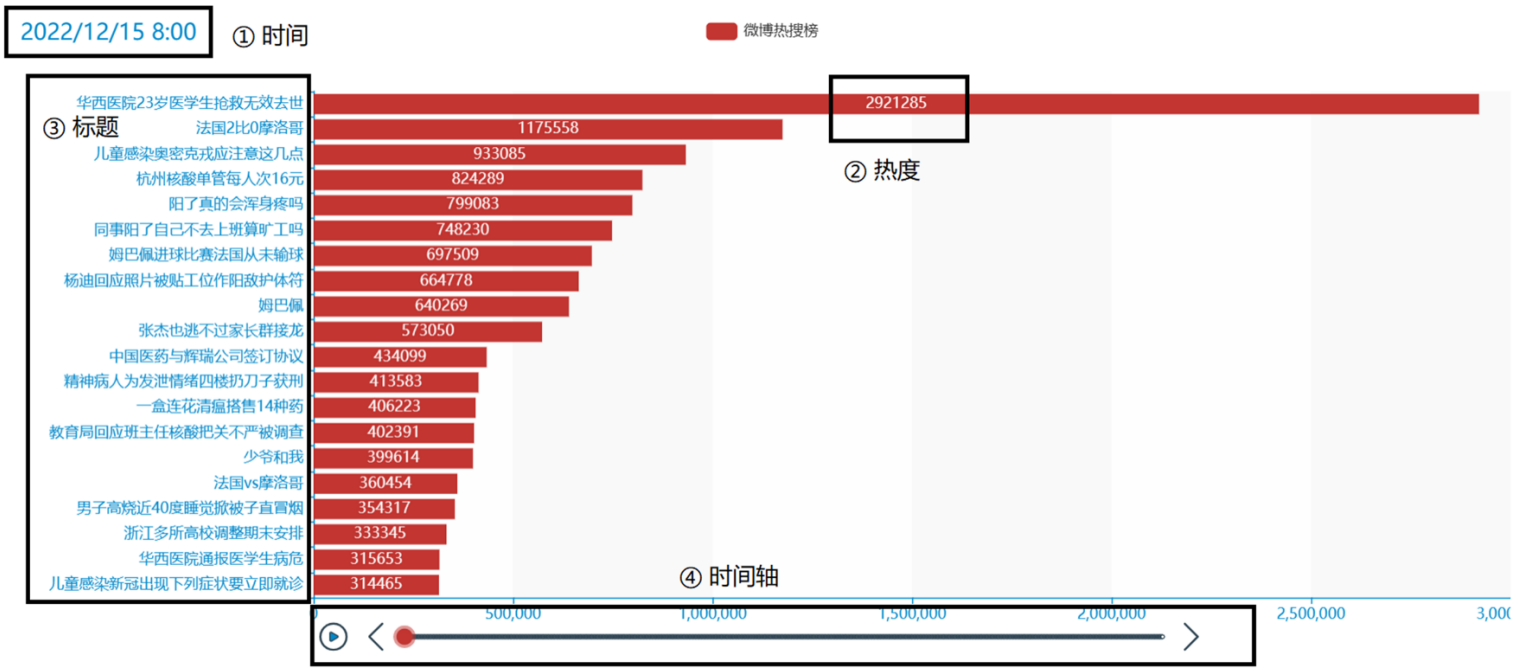

动态效果图可以在附件运行 hot.html 查看，时间轴可以播放也可以随意拖动。

4.3.4 情感分析

情感分析做了三个版本，一天中的情感分析（间隔 10 分钟）、七天的情感分析（间隔 1 天）、七天的情感分析（间隔 1 小时）。用 plotly.express 绘制，x 轴可以放大缩小拖动。

①首先是第一个，以 21 号为例，当天下午得分较低，晚上得分持续走高。总体评分是积极的，其他六天也是如此，看来互联网舆论控评还是往积极走。

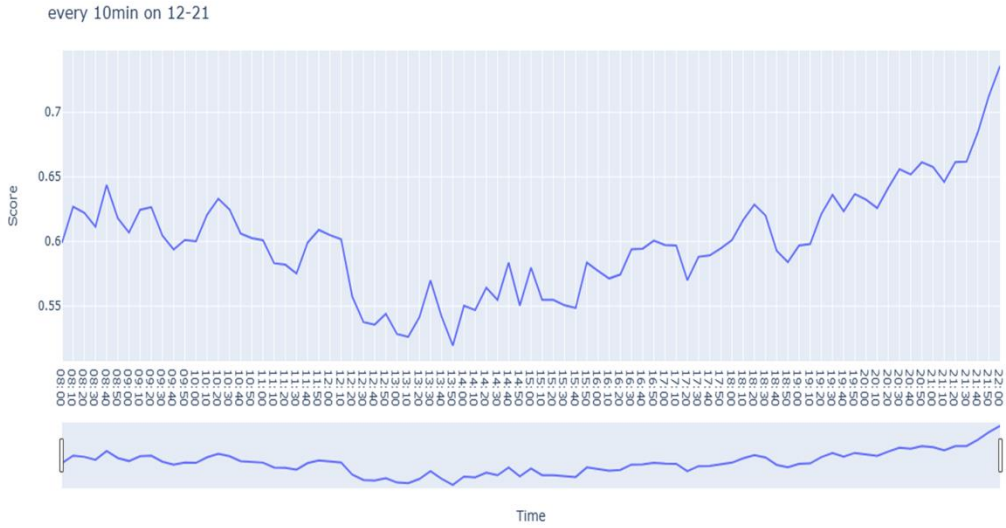

② 其次是七天的情感分析均值对比

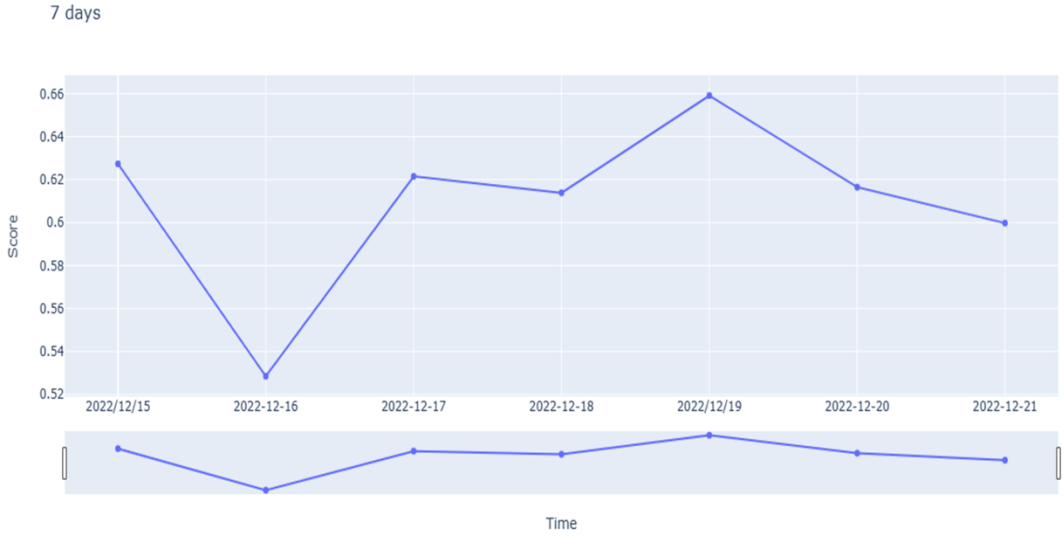

从中可以很清晰地看出，评分最低的是 12 月 16 号，最高是 19 号，结合先前的词云图以及 top20，可以看到 16 号主要是“布洛芬”“阳性”“感染”“新冠”，而 18 号 23 点世界杯决赛开始，19 号的关键词是“阿根廷夺冠”“梅西”“布洛芬”等。放开以后疫情对人们的打击还是很沉重的，而世界杯，特别是阿根廷夺冠，对人们精神的鼓舞也很显著。

③ 最后是七天内间隔一小时的情感分析图：

这张图波动就比较直观了，可以清楚地看到每天的波峰波谷，直接根据时间查到对应那一小时的热搜，美中不足的是缺乏晚上的统计，无法比较 emo 到底是晚上多还是白天多，但微博热搜的情感倾向是有所控制的，即使有统计也并不准确，不如去看网易云评论。所以每天只截取到晚上十点。

三张图要注意时间的获取，十分钟是隔 50 条取一次，且一天内的只获取后半几点几分的时间：

```
    time = []
    for i in range(0, len(data), 50): # 每隔50行取数据
        date = data.iloc[i, 4].split()[1]
        time.append(date)
```

一天是隔 4250 条取一次，只获取几号这个世界，按空格划分：

```
    time = []
    for i in range(0, len(data), 4250):
        date = data.iloc[i, 4].split()[0]
        time.append(date)
```

一小时是隔 300 条取一次，同样只获取后半时间：

```
    time = []
    for i in range(0, len(data), 300):
        date = data.iloc[i, 5].split()[1]
        time.append(date)
```

clean(f_1)函数处理后重新标号，会多一列行号，所以 data.iloc[i,5]，不是第 4 列。同时，为了明确七天划分的界限，增加了虚线和文本示意：

```
    fig.add_trace(go.Scatter(x = [7, 21, 35, 49, 63, 77, 91],
```

```
                    y = [0.715, 0.715, 0.715, 0.715, 0.715, 0.715, 0
.715], line_dash = 'dash',
                    text = ['12-15', '12-16', '12-17', '12-18', '12-
19', '12-20', '12-21'],
                    mode = 'text'))
    for i in range(6):
        i += 1
        fig.add_vline(x = 14*i, line_dash = 'dash')
```

4.3.5 多项式拟合

首先用 dataframe 统计了上榜频次

```
14    print(data.iloc[:, 0].value_counts())
```

```
PROBLEMS    OUTPUT    TERMINAL    DEBUG CONSOLE

          > python -u "d:\code\INTRODUCTION.py\nihe.py"
考研                  179
阿根廷冠军              85
大概率都会感染越晚变阳症状越轻      71
姨妈期杀疯了的免疫系统          71
车保罗                 69
```

选取了频次最高的“考研”，出现了 179 次，然后用 numpy 库的 polyfit 函数进行多项式拟合，结合 poly1d 函数一起使用。

一开始想用最小二乘法估计参数，但是没找到合适的函数，于是用多项式尝试了一下，拟合阶数为 70 次：

```
    z1 = np.polyfit(x, y, 70)
    p1 = np.poly1d(z1)
    fx = p1(x)    # 求对应 x 的各项拟合函数值

    # 绘制坐标系散点数据及拟合曲线图
    plot1 = plt.plot(x, y, label = 'origin data')
    plot2 = plt.plot(x, fx, 'r', label = 'polyfit data')
```

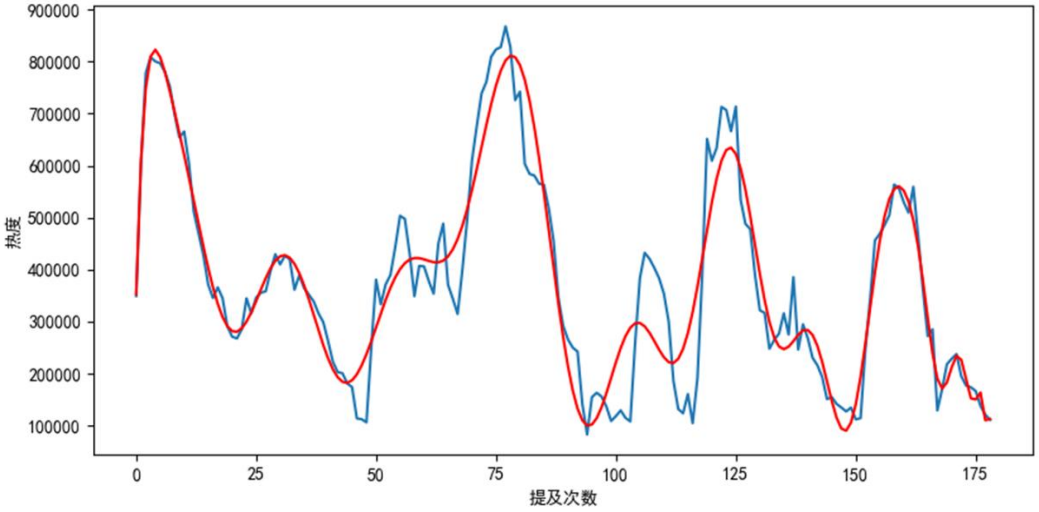

可以看出，拟合的结果还是比较准确的。提及次数与热度变化没有必然的联系。整体趋势是波动下降的，有点像自由落体，前面波峰大但间隔远，后面波峰多间隔近。

5 实验评价

该项目是基于微博热搜榜的一系列数据可视化与分析，中间有遇到很多困难，不管是技术上还是生活中，但最终还算是圆满落幕。爬虫是遇到的第一个难关，本来是想爬取热搜时光机（https://www.weibotop.cn/2.0/），可以爬取历史数据，扩大数据集，但是加密太好了，且爬虫只是开头，后续还有很多工作时间不好把握，于是直接爬取微博（https://s.weibo.com/top/summary?cate=realtimehot），还用任务计划程序反复执行，不愧是万事开头难。项目中的难度还有中文文本处理和画图，比如词语分割，nlp 真的好难，所以最后还是用了 snownlp 库，没有建模。画图也有各种库：plotly.express、plotly.graph_objects、matplotlib.pyplot 和 pyecharts，很多图表类型是第一次画，比如动态柱状图和交互式折线图。最后多项式拟合，本来也打算建模的，还是用了 numpy 库。

总的来说，对于这个多事之秋，项目完成得还可以。

6 后续工作

该项目还有如下一些想法没来得及实现，打算在后续优化完成：

① 重新或继续爬虫扩大数据集，以实现更多探索。其实最开始想做全年的情感分析，但是数据集无法支持，就对这七天做了详细分析。

② 建立情感分析模型。比如用 TF-IDF 进行文本特征处理，再建模。

③ 建立拟合和热搜预测模型。后来想到了 Logistic 逻辑回归模型，可以把热度改为累计热度，初期增长迅速，后期放缓，呈 s 型，再用最小二长发估计拟合，应该可以。

7 结论

① 结合词云和情感分析，得出：未感染人群对感染新冠很担忧，感染人群很痛苦，布洛芬很热销。阿根廷夺冠网友很激动，梅西第一次世界杯夺冠。

② 通过每小时的情感分析，得出：除 15 号外，其余每天 8:00 到 9:00 微博热搜的负面情感有所增加，网友都不太喜欢早起。

③ 通过动态柱状图，得出：通常热搜第一的热度一骑绝尘，偏向实时爆炸性新闻和社会焦点，热度要高出好几倍，偏向昙花一现。

④ 通过多项式拟合，得出：提及次数与热度并不是正相关，只能说明一直有持续关注，提及次数与热度变化没有必然的联系。整体趋势是波动下降的，有点像自由落体，前面波峰大但间隔远，后面波峰多间隔近。更爆炸性的新闻在不断诞生冲击榜首。